

Page d'accueil

Construisez et testez une infrastructure de données

50 heures

Qu'allez-vous apprendre dans ce projet ?

Vous disposez désormais d'un large panel de savoirs théoriques et pratiques pour concevoir une architecture de base de données qui répond aux enjeux d'une organisation. Vous avez vu comment concevoir une architecture des données, collecter et stocker ces dernières dans une base de données hébergée dans le cloud, et tester l'intégrité des données.

Si vous souhaitez ancrer votre apprentissage, vous pouvez vous entraîner à l'aide de [ces questions](#).

Dans ce projet, vous allez assembler ces compétences pour valider vos acquis. Vous démontrerez votre compréhension claire et structurée de la méthodologie de travail du Data Engineer. Vous travaillerez avec différentes sources de données, vous devrez les collecter et les transformer. Puis, vous les stockerez dans une base de données hébergée sur AWS via un conteneur Docker. Enfin, vous devrez appliquer les recommandations de sécurité sur vos données ce qui comprend leur réplication et la mise en place de tests de leur intégrité.

En quoi ces compétences sont-elles importantes pour votre carrière ?

Votre quotidien futur de Data Engineer sera essentiellement constitué des activités suivantes :

- Structurer et concevoir des bases de données robustes
- Formaliser les processus de traitement et de stockage des données
- Modéliser des infrastructures compatibles avec le système d'information

Il vous faudra également installer et configurer les systèmes de gestion de bases de données et leurs outils d'extraction.

Enfin, vous devrez établir et formaliser les processus de test pour garantir la performance et la sécurité.

Les compétences que vous validerez dans ce projet sont donc cruciales pour votre futur métier et vous serviront à garantir la qualité, la fiabilité et la sécurité des données de vos organisations.

Comment allez-vous procéder ?

Ce projet est constitué d'une mission que vous devrez réaliser de bout en bout.

- **Mission** : Vous réaliserez la collecte des données météorologiques de plusieurs stations, et vous stockerez ces données dans un conteneur Docker hébergé sur AWS.
 - Vous terminerez en complétant la fiche d'autoévaluation qui servira de base de discussion avec votre mentor avant la soutenance.

À l'issue de ce projet, vous présenterez les livrables de la mission à un mentor évaluateur lors d'une **soutenance**.

Cela vous permettra de valider les compétences visées par ce projet.

Prêt à démarrer votre projet ?

Lancez-vous dans la première partie de la mission.

Votre projet démarre : suivez ces quelques recommandations pour être plus efficace !


- **Coupez** dès à présent toutes les sources de distraction : téléphone, messagerie, mails, notifications, etc.

- **Évitez** les situations de multi tâches : n'écoutez pas un podcast ou les informations en travaillant.
- **Préparez** votre environnement de travail : onglets, documents téléchargés, raccourcis, etc.

Vous avez toutes les cartes en main, c'est parti !

Pour plus de conseils, suivez ce chapitre de cours : **Mettez en place votre environnement d'apprentissage.**

Cours - Initiez-vous au logiciel Airbyte



Pourquoi suivre ce cours ?

Vous allez découvrir le logiciel Airbyte. Vous découvrirez comment l'installer et prendre en main ses principales fonctionnalités.

Il est essentiel de rester attentif à **l'ensemble** du cours.

Cliquez sur l'image ci-dessous pour consulter le cours.



DATA - COURS

Initiez-vous au logiciel Airbyte pour intégrer vos données

Facile 6 heures

Installez Airbyte sur votre ordinateur et utilisez les principales fonctionnalités de cet outil pour extraire vos données.

Mission - Construisez et testez une infrastructure



Comment allez-vous procéder ?

Cette mission suit un scénario de projet professionnel.

Vous pouvez suivre les étapes pour vous aider à réaliser vos livrables.

Avant de démarrer, nous vous conseillons de :

- lire toute la mission et ses documents liés ;
- prendre des notes sur ce que vous avez compris ;
- consulter les étapes pour vous guider ;
- préparer une liste de questions pour votre session de mentorat.

Prêt à mener la mission ?

Vous êtes nouvellement embauché comme Data Engineer dans l'entreprise GreenAndCoop, un fournisseur coopératif français d'électricité d'origine renouvelable dans les Hauts-de-France.

En tant que Data Engineer, votre travail est de fournir quotidiennement des données météorologiques de qualité aux Data Scientists pour leurs modèles de prévision. La prévision de demande est essentielle pour GreenCoop.

L'entreprise souhaite :

1. équilibrer le réseau : GreenCoop doit s'assurer que la production et la consommation d'électricité sont équilibrées en temps réel pour éviter des pénalités financières.
2. optimiser la production : Les sources d'énergie renouvelable, comme le solaire et l'éolien, sont intermittentes. En prévoyant la demande, GreenCoop peut planifier plus efficacement l'utilisation de ses ressources et maximiser l'efficacité de la production.
3. gérer ses coûts : Une prévision précise de la demande permet de réduire les coûts liés à l'achat d'électricité sur le marché de gros, en évitant les achats d'urgence à des prix élevés.

Pour gagner en précision dans leurs prévisions, les Data Scientists de GreenCoop ont lancé un nouveau projet qui s'appelle Forecast 2.0. L'objectif de celui-ci est d'intégrer de nouvelles sources de données dans leurs algorithmes comme celles issues de stations météorologiques semi-professionnelles.

Vous êtes associé à ce projet en tant que Data Engineer et votre challenge sera d'**intégrer dans la base des données météorologiques ces nouvelles sources issues de différents serveurs** (stations en open-data du réseau météorologique, stations amateurs info climats, etc.) qui transmettent leurs relevés toutes les 10, 15 ou 30 minutes selon le système de transmission.

En regardant vos mails ce matin, vous découvrez un message d'Ouly, la cheffe du projet Forecast 2.0 qui fait partie de l'équipe Data Science :

De : Ouly

À : Moi

Objet : Forecast 2.0 - Intégration de nouvelles sources de données dans la BDD

Salut,

J'espère que tu vas bien !

Je suis super heureuse que tu nous rejoignes sur ce beau projet. Tu vas nous aider à améliorer nos algorithmes de prévision en les enrichissant de sources de données. On avait besoin d'un bon Data Engineer pour mettre en place un pipeline fiable.

Suite à notre discussion, tu trouveras en pièces jointes les liens vers des sources de données que nous avons trouvées. Ces nouvelles sources vont nous aider. En effet, elles sont dans des localisations où notre modèle de prévision de la demande d'électricité est moins fiable car nous manquons de relevés précis par les stations météorologiques officielles. Ces sources sont le réseau InfoClimat et le réseau Weather Underground. Ce n'est pas encore exhaustif mais cela te permettra de mettre en place les premières briques du pipeline.

Les formats des données sont différents. Nous voulons garder toutes les informations des sources que je t'ai envoyées dans la base de données finale. Il faut donc un schéma qui le permette.

Je ne sais pas si tu es au courant, mais notre DSI nous impose de travailler avec AWS. Si tu peux nous mettre ces données dans une base de données (MongoDB) hébergée sur AWS ce serait top pour nos calculs ensuite (pour info, on utilise SageMaker pour nos travaux de ML donc on pourra se connecter directement).

Nous avons une réunion de l'équipe projet dans 1 mois. Peux-tu préparer une **présentation** pour nous expliquer ta démarche ainsi qu'une **démonstration** ?

Les éléments qui nous intéressent sont les suivants :

- Le schéma de la base de données, pour que nous sachions la requêter pour obtenir les données
- Le processus mis en place pour collecter, traiter, stocker et tester les données (on utilise souvent des logigrammes pour présenter nos processus)
- L'architecture de la base de données
- La stack technique utilisée (les outils/services web utilisés)
- La qualité des données (taux d'erreurs)
- Le temps d'accessibilité aux données

Bon courage à toi et à très bientôt,

Ouly

P.J: Liens vers les sources de données identifiées

1. [Stations météorologiques du réseau InfoClimat \(Bergues, Hazebrouck, Armentières, Lille-Lesquin\)](#)
2. [Station amateur Weather Underground à Ichtegem, Belgique](#)
3. [Station amateur Weather Underground à La Madeleine, France](#)

Cette mission est guidée.

Vous pouvez suivre les étapes ci-dessous.

Étapes

Étape 1 - Récupérez et transformez vos données

Prérequis

- Avoir lu le cours [Initiez-vous au logiciel Airbyte pour intégrer vos données.](#)

Résultats attendus

- Une installation Airbyte permettant de se connecter aux sources de données Excel et JSON pour les charger dans un bucket S3.
- Un script permettant de transformer ces données dans un format compatible avec MongoDB.
- Un Readme expliquant la logique de transformation des données et comment fonctionne le script.
- Un requirements.txt contenant tous les modules (et leur version) nécessaires au bon fonctionnement de votre environnement virtuel.

Recommandations

Documentez systématiquement votre travail. Une bonne documentation, y compris un journal de bord ou un rapport de progression, peut aider à suivre les étapes franchies, les défis rencontrés, et les solutions trouvées.

- Créez un bucket S3 sur AWS.
- Connectez-vous aux sources de données via Airbyte pour les importer dans S3.
- Transformez vos données afin de les préparer à être importées dans MongoDB via un script Python.
- Testez l'intégrité (colonnes disponibles, types des variables, doublons, valeurs manquantes, etc...) des données avant et après la migration.
- Automatisez le processus de test.

Les métadonnées sur les stations amateurs que vous devez intégrer dans la base de données sont les suivantes :

Weather Station ID: ILAMAD25

Station Name:La Madeleine

Latitude / Longitude:50.659° N,
3.07° E

Elevation:23

City:La Madeleine

State:-/-

Hardware:other

Software:EasyWeatherPro_V5.1.6

Outils

Weather Station ID: IICHTE19

Station Name:WeerstationBS

Latitude / Longitude:51.092° N,
2.999° E

Elevation:15

City:Ichtegem

State:-/-

Hardware:other

Software:EasyWeatherV1.6.6

- [Airbyte](#)
- [Python](#)

Points de vigilance

- Prêtez attention :
 - aux traitements nécessaires sur vos données pour les rendre cohérentes (noms, formats différents) afin que les Data Scientists puissent les requêter facilement ;
 - au typage des champs.

Ressources

- Cours: [Initiez-vous au logiciel Airbyte pour intégrer vos données.](#)
- [Tutorials, Guides and Use Cases | Airbyte](#)

Étape 2 - Migrez vos données vers MongoDB et sécurisez-les

Prérequis

- Avoir lu le cours [Maîtrisez les bases de données NoSQL.](#)

Résultats attendus

- Un script permettant, lorsqu'il est exécuté, de transférer les données dans une base de données MongoDB.
- Une mesure de la qualité des données post migration (i.e. taux d'erreurs dans vos données)
- Un Readme expliquant la logique de la migration et comment fonctionne le script.
 - Il s'agit ici de vous permettre d'acquérir de bonnes pratiques en place, le Readme n'est pas évalué en soutenance.
- Un requirements.txt contenant tous les modules (et leur version) nécessaires au bon fonctionnement de votre environnement virtuel.
- Le processus suivi de collecte, transformation et stockage des données formalisé via un logigramme.
 - Les logigrammes comprennent un certain nombre de formes codifiées.
 - Assurez-vous de bien les connaître.

Recommandations

Documentez systématiquement votre travail. Une bonne documentation, y compris un journal de bord ou un rapport de progression, peut aider à suivre les étapes franchies, les défis rencontrés, et les solutions trouvées.

- Créez et manipulez une ou plusieurs collections MongoDB pour accueillir vos données.
- Utilisez les commandes de base pour **CRUD** (Create, Read, Update, Delete) dans MongoDB via un script python.
- Importez l'ensemble des données dans MongoDB.
- Mettez en place des répliquions pour vos données.

Outils

- [Python](#)
- [MongoDB](#)

Points de vigilance

- Prêtez attention :
 - au choix du schéma pour l'importation future de vos données dans MongoDB, posez-vous également la question "dois-je créer une ou plusieurs collections ?" ;
 - au contrôle du schéma pour vérifier l'intégrité de votre base de données.

Ressources

- Cours : [Maîtrisez les bases de données NoSQL](#).
- Ressource pédagogique : [validation de schéma avec MongoDB](#)
- [Qu'est-ce qu'un logigramme : définition, exemples et utilité](#) | Lucidchart

Étape 3 - Conteneurisez l'application avec Docker

Prérequis

- Avoir lu le cours [Optimisez votre déploiement en créant des conteneurs avec Docker](#).

Résultat attendu

- Un docker-compose permettant de déployer et d'exécuter votre migration de données au sein de différents conteneurs et/ou volumes.
- Vous devrez pouvoir démontrer sur demande que votre migration fonctionne bien.

Outils

- [Docker](#)

Points de vigilance

- Importation des images Docker appropriées.
- Utilisation d'au moins un volume.

Ressources

- Cours: [Optimisez votre déploiement en créant des conteneurs avec Docker](#).

Étape 4 - Déployez sur AWS

Prérequis

- Avoir lu la ressource [Qu'est-ce que le stockage dans le cloud ?](#)

Résultats attendus

- Déploiement d'une instance MongoDB dans un conteneur Docker sur Amazon ECS (Elastic Container Service).
- Un reporting avec le temps d'accessibilité à vos données mesuré via le temps d'exécution d'une requête (par exemple récupérer les données météo liées à une journée donnée dans un lieu donné).
- Configuration des sauvegardes et surveillance des bases de données sur AWS.

Recommandations

Surveillez votre onglet facturation (billing) sur AWS et clôturez les services utilisés à l'issue du projet au risque de vous voir facturé inutilement. Consultez le chapitre Maîtrisez les outils de facturation sur AWS du cours "Découvrez le cloud avec Amazon Web Services" à ce sujet.

Ressources

- [Qu'est-ce que le stockage dans le cloud ?](#)

Étape 5 - Concevez votre support de présentation et préparez votre soutenance

Prérequis

- Avoir finalisé votre travail.

Résultat attendu

Un support de présentation rappelant :

- le contexte de la mission ;
- la description de votre démarche technique complète ;
- la justification de vos choix.

et incluant :

- le schéma de la base de données ;
- le logigramme du processus suivi pour collecter, transformer, stocker et tester les données ;
- l'architecture de la base de données ;
- l'installation mise en place pour Airbyte (qui sera attestée par une capture d'écran dans votre support de présentation) ;
- un reporting sur le temps d'accessibilité aux données et qualité des données ;
- l'installation mise en place pour AWS (qui sera attestée par une capture d'écran dans votre support de présentation).

Recommandations

- Structurez la présentation en commençant par rappeler le contexte et les objectifs du projet. Présentez ensuite les étapes clés (collecte de données, traitement, etc.).
- Réfléchissez aux éléments critiques que vous souhaitez montrer dans la démonstration.
- Vous n'aurez que quelques minutes pour la démonstration au sein de la soutenance, assurez-vous donc que la démo est fluide et que ce que vous présentez est pertinent pour votre interlocuteur (Qu'est-ce qui est important pour Ouly ?).
- Utilisez des schémas plutôt que du texte pour expliquer les technologies choisies.
- Entraînez-vous à effectuer vos démonstrations en 3 minutes.
- Anticipez les questions techniques sur les choix technologiques. Soyez capable de justifier toutes vos décisions.
- Soyez prêts à discuter des éventuelles améliorations que vous pourriez apporter au projet, aussi bien sur le plan technique que fonctionnel.
- Soignez la forme avec des slides claires et concises (des visuels, des schémas, logigrammes, etc.).
- Et bien sûr préparez votre discours afin qu'il soit fluide et naturel (évitez de lire vos notes).
- Répétez à l'avance.

Ressources

- Cours : [Améliorez l'impact de vos présentations](#)

Étape 6 - Vérifiez votre travail et faites le point avec votre mentor

Pour vérifier que vous n'avez rien oublié dans la réalisation de votre exercice, téléchargez et complétez la [fiche d'autoévaluation](#).

Parlez-en avec votre mentor durant votre dernière session de mentorat.

Livrables et soutenance

Livrables et soutenance



Livrables

Voici un rappel des documents que vous devez déposer sur la plateforme.

Activité

Mission - Construisez et testez une infrastructure de données

Livrables

Une présentation au format PowerPoint (ou autre logiciel similaire) avec :

1. le schéma de la base de données ;
2. le logigramme du processus suivi pour collecter, transformer, stocker et tester les données ;
3. le schéma de l'architecture de la base de données ;
4. une capture d'écran pour montrer l'installation mise en place pour Airbyte ;
5. un reporting sur temps d'accessibilité aux données et la qualité des données ;
6. une capture d'écran pour montrer l'installation mise en place pour AWS.

Déposez sur la plateforme, dans un dossier zip nommé

Titre_du_projet_nom_prenom, tous les livrables du projet comme suit :

Nom_Prenom_n° du livrable_nom du livrable_date de démarrage du projet.

Cela donnera :

- *Nom_Prenom_1_support de presentation_mmaaaa*

Par exemple, le premier livrable peut être : *Janek_Meriem_1_support de presentation_012025*

Soutenance

Durant la présentation orale, l'évaluateur interprétera le rôle de Ouly qui veut s'assurer que votre travail respecte bien les spécifications techniques données par l'équipe projet.

La soutenance dure 30 minutes et sera structurée de la manière suivante :

- **Présentation des livrables (15 minutes)**
 - Introduisez le contexte de GreenCoop, du projet Forecast 2.0 et les grandes lignes de votre travail.
 - Détaillez à l'aide de votre support de présentation le processus utilisé pour collecter les données des nouvelles sources, le schéma de la base de données et la qualité des données obtenue in fine.
 - Expliquez l'architecture de la base de données ainsi que celle des services Airbyte et Docker utilisés.
 - Faites une démonstration de l'utilisation d'Airbyte et d'AWS en vous appuyant sur vos captures d'écran (connecteurs Airbyte et dashboard AWS).
- **Discussion (10 minutes)**
 - Toujours dans le rôle d'Ouly, l'évaluateur vous challengera sur les points suivants :
 - Votre raisonnement logique quant au processus suivi, le schéma de votre base de données et votre architecture.
 - Votre implémentation des différentes technologies utilisées.

- Votre documentation des décisions prises.
- **Debrief (5 minutes)**
 - À la fin de la soutenance, l'évaluateur arrêtera de jouer le rôle de la cheffe de projet pour vous permettre de débriefer ensemble.

Votre présentation doit durer 15 minutes (+/- 5 minutes). Puisque le respect des durées des présentations est important en milieu professionnel, les présentations en dessous de 10 minutes ou au-dessus de 20 minutes peuvent être refusées.